

EUR/USD 1H Forex Zaman Serisi Tahmini ve Simülasyon Tabanlı Demo

Yapay Zekaya Giriş Dersi Final Teknik Raporu

Bilal Burak Tekin | b200101025

Sakarya Uygulamalı Bilimler Üniversitesi | Elektrik-Elektronik Mühendisliği

GitHub: [somethinkwronghere/yapay-zeka-donem-projesi](https://github.com/somethinkwronghere/yapay-zeka-donem-projesi)

Bu çalışma akademik amaçlıdır; finansal tavsiye değildir. Rapor, ders kılavuzundaki yapay zeka proje yaşam döngüsüne göre hazırlanmıştır.

Özet

Bu rapor, EUR/USD paritesinin saatlik kapanış değerleri üzerinde geliştirilen yapay zeka dönem projesini uçtan uca açıklar. Çalışma; ham veri yönetimi, keşifsel veri analizi, öznitelik mühendisliği, baseline modelleme, klasik makine öğrenmesi, derin öğrenme, metrik değerlendirmesi ve Streamlit tabanlı çalışan demo adımlarını içerir.

Test kümesinde en iyi yön doğruluğu XGBoost ile %51.53 seviyesine ulaşmıştır. RMSE tarafında AR(1), naive son değer ve drift baselineleri yaklaşık 10.06 pip hata ile çok güçlü kalmıştır. Bu durum finansal zaman serilerinin kısa vadede rassal yürüyüşe yakın davranmasını destekler.

Anahtar Kelimeler: EUR/USD, zaman serisi tahmini, makine öğrenmesi, LSTM, Transformer, Streamlit, forward testing.

İçindekiler

- 1. Giriş ve Problem Tanımı
- 2. Proje Kılavuzu ile Uyum
- 3. Veri Seti ve Veri Yönetimi
- 4. Keşifsel Veri Analizi
- 5. Öznitelik Mühendisliği
- 6. Baseline Modeller
- 7. Klasik Makine Öğrenmesi
- 8. Derin Öğrenme
- 9. Metrikler ve Sonuçlar
- 10. Streamlit Demo
- 11. Canlı Veri ile Model Karşılaştırması
- 12. Test ve Teslim Paketi
- 13. Etik, Riskler ve Gelecek Çalışmalar
- 14. Sonuç, Kaynakça ve Ekler

1. Giriş ve Problem Tanımı

Finansal piyasalar doğrusal olmayan, gürültülü ve rejim değişimlerine açık sistemlerdir. EUR/USD paritesi küresel likidite, merkez bankası kararları, makroekonomik veri akışı ve piyasa beklentilerinden etkilendiği için kısa vadeli tahmin problemi hem zorlu hem de öğreticidir.

Proje, ders kılavuzundaki Stock Market Prediction başlığını döviz piyasasına uyarlamıştır. Amaç, geçmiş OHLCV mumlarından ve teknik özniteliklerden yararlanarak gelecekteki kapanış seviyesi veya yönü hakkında model çıktısı üretmek ve bu çıktıları çalışan bir arayüzde göstermektir.

Bu problem sadece model eğitimi olarak ele alınmamıştır. Veri toplama, temizleme, notebook çıktıları, tekrar kullanılabilir kaynak kod, metrik tablosu, model dosyaları, Streamlit demo, ekran videosu ve teknik rapor aynı teslim paketinin parçaları olarak yönetilmiştir.

Boyut	Projedeki karşılığı
Problem türü	Saatlik EUR/USD kapanış tahmini ve yön analizi
Girdi	OHLCV, spread, takvim ve teknik gösterge özellikleri
Çıktı	Bir sonraki veya çok adımlı kapanış / log-getiri tahmini
Başarı ölçütleri	RMSE, MAE, MAPE, yön doğruluğu, pip bazlı hata
Demo hedefi	Streamlit arayüzünde model, metrik ve senaryo gösterimi

2. Proje Kılavuzu ile Uyum

Ders kılavuzu çalışan ve test edilebilir bir sistem ortaya koymayı zorunlu tutar. Repo bu beklentiye göre /data, /notebooks, /src, /api ve /docs klasörlerinden oluşacak biçimde düzenlenmiştir. Böylece veri, analiz, kaynak kod, demo ve rapor ayrımı açıktır.

Kılavuz gereksinimi	Karşılanan çıktı
GitHub ve düzenli commit	Repo 21 commit ile yürütülmüştür.
README ve kurulum açıklaması	README.md ve api/README.md güncellenmiştir.
Veri klasörü	data/raw ve data/processed içerikleri hazırdır.
Notebook teslimleri	EDA, baseline, ML ve DL defterleri mevcuttur.
Model dosyası	LSTM ve Transformer checkpoint dosyaları .pt olarak kaydedilmiştir.
Çalışan demo	api/app.py Streamlit paneli olarak çalışmaktadır.
Video tutorial	eurusd_demo_screen_video.mp4 hazırlanmıştır.

AI Proje Yaşam Döngüsü

- Problem tanımlama: EUR/USD H1 kısa vadeli tahmin problemi ve akademik kullanım sınırı belirlendi.
- Veri toplama: Kaggle ve MT5 kaynaklı genişletilmiş EUR/USD mum verisi repoya eklendi.
- EDA: dağılım, volatilité, ACF/PACF, takvim ve seans etkileri görselleştirildi.
- Model geliştirme: baseline, klasik ML ve PyTorch tabanlı DL modelleri karşılaştırıldı.
- Dağıtım: Streamlit arayüzü yerelde çalışır hâle getirildi.

3. Veri Seti ve Veri Yönetimi

Ham veri seti 100,609 adet saatlik mumdan oluşur. Zaman aralığı 2009-10-16 00:00:00 ile 2026-01-06 07:00:00 arasındadır. Sütunlar time, open, high, low, close, tick_volume, spread ve real_volume alanlarını içerir.


Veri src/data_loader.py içindeki yükleyici ile zaman indeksine dönüştürülür, kronolojik sıralanır ve tekrarlı zaman damgaları son kayıt kalacak şekilde temizlenir. Zaman serisi karıştırılmadan train, validation ve test dönemlerine ayrılmıştır.

Özellik	Açıklama
Parite	EUR/USD
Zaman çözünürlüğü	1 saatlik mum
Satır sayısı	100,609
İlk gözlem	2009-10-16 00:00:00
Son gözlem	2026-01-06 07:00:00
Ham sütun sayısı	8
Veri ayrımı	Train: 2009-2022, Validation: 2023, Test: 2024 sonrası

Ham fiyat seviyesinin durağan olmaması beklenen bir durumdur. Bu nedenle modelleme tarafında log-getiri, rolling volatilité, lag özellikleri ve takvim/seans bilgileri kullanılmıştır.

4. Keşifsel Veri Analizi

EDA aşamasının amacı model kurmadan önce serinin istatistiksel yapısını anlamaktır. Notebook çıktıları fiyat seviyesinin uzun vadede rejim değişimleri yaşadığını, log-getirilerin sıfır çevresinde yoğunlaştığını ve volatilitenin kümelenme eğilimi gösterdiğini göstermiştir.




Şekil 1. EUR/USD kapanış, log-getiri ve rolling volatilité görünümü.

Bu görünüm, model seçimini doğrudan etkiler. Kısa vadeli fiyat seviyesi değişimleri küçük olsa da volatilité dönemsel olarak yükselir. Bu nedenle tek bir global metrik yerine farklı metriklerin birlikte değerlendirilmesi gerekir.

5. Öz nitelik Mühendisliği

Öz nitelik üretimi src/features.py içinde fonksiyonlara ayrılmıştır. Bu modül log-getiri, rolling mean/std, takvim bilgisi, seans etiketleri, lagged return, volatilité, RSI, ATR, high-low range ve open-close change alanlarını üretir.

Öz nitelik ailesi	Kullanım nedeni
Log-getiri	Fiyat seviyesini daha durağan ve ölçeklenebilir temsil eder.
Rolling istatistikler	Kısa ve orta vadeli trend/volatilité bilgisini taşır.
Lag özellikleri	Otoregresif bağımlılıkları modele verir.
Takvim ve seans	Piyasa likiditesi ve işlem saatlerindeki düzenleri yakalar.
RSI / ATR	Momentum ve volatilité rejimini teknik gösterge olarak özetler.
Mum aralığı	Saatlik belirsizlik ve gövde/fital davranışını temsil eder.




Şekil 2. Üretilen özelliklerin korelasyon görünümü.

6. Baseline Modeller

Naive son değer, drift, seasonal naive 24H/168H, 24 saatlik hareketli ortalama ve AR(1) modelleri baseline olarak kullanılmıştır. Forex gibi kısa vadede rassal yürüyüşe yakın serilerde naive model güçlü bir referans noktasıdır.

Model	RMSE pip	MAE pip	MAPE	Yön %
ar(1)	10.06	6.40	0.0579	49.94
naive_last_value	10.06	6.40	0.0579	0.00
drift	10.06	6.40	0.0579	49.66
ma_24h	10.26	6.64	0.0601	49.92
seasonal_naive_168h	14.14	9.41	0.0851	49.73
seasonal_naive_24h	14.17	9.31	0.0842	50.52




Şekil 3. Baseline modellerin skor karşılaştırması.

Sonuçlar, RMSE bakımından AR(1), naive ve drift modellerinin birbirine çok yakın olduğunu göstermiştir. Bu durum sonraki modellerin gerçekten anlamlı bir iyileştirme sağlayıp sağlamadığını ölçmek için önemlidir.


7. Klasik Makine Öğrenmesi Modelleri

Random Forest, XGBoost ve LightGBM modelleri tabular özelliklerden doğrusal olmayan karar kuralları çıkarabildiği için denenmiştir. Bu modeller rolling volatilité, lagged return, takvim ve teknik göstergelerden yararlanır.

Model	RMSE pip	MAE pip	Yön doğruluğu %
xgboost	10.17	6.57	51.53
random_forest	10.14	6.55	51.34
lightgbm	10.18	6.56	51.28



Şekil 4. Klasik ML modellerinin baseline ailesiyle karşılaştırılması.




Şekil 5. ML modellerinde öne çıkan özellikler.


8. Derin Öğrenme Modelleri

PyTorch ile LSTMForecaster ve TransformerForecaster mimarileri hazırlanmıştır. LSTM sıralı bağımlılıkları kapı mekanizmasıyla işlerken Transformer encoder self-attention kullanır. Modeller CPU üzerinde eğitilebilir kalacak şekilde küçük tutulmuştur.

Model	RMSE pip	MAE pip	Yön doğruluğu %
lstm	10.93	7.28	50.47
transformer	11.89	8.33	49.91



Şekil 6. Derin öğrenme eğitim eğrileri.



Şekil 7. Derin öğrenme sonuçlarının tüm modellerle değerlendirilmesi.

9. Metrikler ve Sonuçların Yorumlanması

Projede RMSE, MAE, MAPE, pip bazlı hata ve directional accuracy birlikte kullanılmıştır. En düşük fiyat hatası ile en iyi yön tahmini her zaman aynı modelden gelmeyebilir; bu nedenle raporda her iki bakış açısı da korunmuştur.

Model	RMSE pip	MAE pip	MAPE	Yön %
xgboost	10.17	6.57	0.0594	51.53
random_forest	10.14	6.55	0.0592	51.34
lightgbm	10.18	6.56	0.0593	51.28
seasonal_naive_24h	14.17	9.31	0.0842	50.52
lstm	10.93	7.28	0.0659	50.47
ar(1)	10.06	6.40	0.0579	49.94
ma_24h	10.26	6.64	0.0601	49.92
transformer	11.89	8.33	0.0751	49.91
seasonal_naive_168h	14.14	9.41	0.0851	49.73
drift	10.06	6.40	0.0579	49.66
naive_last_value	10.06	6.40	0.0579	0.00

Yön doğruluğunda XGBoost, Random Forest ve LightGBM öne çıkmıştır. RMSE bakımından ise AR(1) ve naive baselineleri güçlüdür. Bu sonuç, finansal serilerde karmaşık modelin otomatik olarak daha iyi sonuç üretmediğini gösterir.

10. Streamlit Demo ve Kullanıcı Arayüzü

api/app.py dosyası tam bir Streamlit paneline dönüştürülmüştür. Arayüzde model seçimi, tahmin ufku, geçmiş pencere, senaryo sayısı, forward-test uzunluğu ve bitiş tarihi kontrolleri bulunur. Ana ekranda son kapanış, volatilité, seçilen modelin RMSE değeri ve yön doğruluğu gösterilir.

Sekme	İçerik
Tahmin paneli	Geçmiş kapanış, seçilen model tahmini, senaryo bandı ve CSV indirme.
Forward test	Rolling RMSE, MAE, yön isabeti ve gerçek/tahmin grafiği.
Model karşılaştırma	Test skorlarının aile bazlı dağılımı ve skor tablosu.
Veri ve EDA	Ham veri özeti, son veri kesiti ve rapor görselleri galerisi.

Demo kontrolleri

Model

XGBoost

Tahmin ufku

48 saat

Geçmiş pencere

45 gün

Senaryo sayısı

80

Forward test

240 saat

Bitiş tarihi

2026/01/06

Saat

7

EUR/USD 1H AI Forecast Demo

Yapay Zekaya Giriş dönem projesi için Streamlit arayüzü: veri kesiti, tahmin, senaryo, metrik ve forward-test paneli.

Son kapanış

1.17286

↑ +43.3 pip

168H volatilité

5.79 bp

Seçilen model RMSE

10.17 pip

Test yön doğruluğu

51.53%

Tahmin paneli

Forward test

Model karşılaştırma

Veri ve EDA




Şekil 8. Streamlit demo tahmin paneli ekran görüntüsü.

11. Canlı Veri ile Model Karşılaştırması


Son güncellemede demo, Yahoo Finance üzerindeki EURUSD=X saatlik verisini çekebilecek şekilde genişletilmiştir. Canlı veri paneli, son mumları candlestick olarak gösterir ve model çıktılarıyla aynı grafikte karşılaştırır. LSTM ve Transformer çizgileri kayıtlı .pt checkpoint dosyalarından gerçek PyTorch inference ile üretilir; XGBoost, Random Forest, LightGBM ve baseline çizgileri ise sunum amaçlı proxy karşılaştırma yollarıdır.

Modelin eğitildiği görev t+1 log-getiri tahminidir. Bu nedenle canlı panelde ilk adım doğrudan checkpoint çıktısıdır. Daha uzun ufukta gösterilen çizgi, bu sinyalin sönümlü senaryo yoludur. Gerçek performans yorumu için rolling canlı karşılaştırma tablosu ve t+1 gerçek-vs-tahmin grafikleri kullanılır.


Model	Canlı RMSE pip	Canlı MAE pip	Canlı yön %
LSTM	6.83	4.90	40.62
Transformer	10.54	8.99	41.67



Şekil 9. Canlı EUR/USD mumları üstünde model tahmin yolları.



Şekil 10. Canlı veri üzerinde checkpoint t+1 tahminleri ve gerçekleşen kapanış.



Şekil 11. Canlı rolling pencerede LSTM ve Transformer hata metrikleri.



Şekil 12. Canlı, veri seti sonu ve 2020 volatilité döneminden mum grafiği örnekleri.

12. Test, Sürümler ve Teslim Paketi

Son geliştirme turunda Streamlit uygulaması yerel sanal ortamda çalıştırılmış, tarayıcıda tahmin paneli, forward test ve model karşılaştırma sekmeleri kontrol edilmiştir. Ekran videosu çalışan yerel uygulamadan üretilmiştir.

Teslim kalemi	Dosya / konum
GitHub repo	somethinkwronghere/yapay-zeka-donem-projesi
Çalışan demo	api/app.py
Tema ayarı	.streamlit/config.toml
Ham veri	data/raw/eurusd_h1.csv
Skorlar	data/processed/all_model_scores.csv
Checkpoint	data/processed/checkpoints/lstm.pt, transformer.pt
Ekran videosu	outputs/eurusd_demo_screen_video.mp4
Final rapor	outputs/eurusd_ai_forecast_final_raporu.docx / .pdf

Çalıştırma

- python -m venv .venv
- .venv\Scripts\Activate.ps1
- pip install -r requirements.txt
- streamlit run api/app.py

13. Etik, Riskler ve Gelecek Çalışmalar

Proje finansal piyasa verisi kullandığı için etik ve sorumluluk bölümü önemlidir. Demo arayüzünde ve raporda model çıktılarının finansal tavsiye olmadığı açıkça belirtilmiştir. Sistem gerçek işlem kararı için kullanılmamalıdır.

Risk	Açıklama	Önlem
Overfitting	Model geçmiş veriye fazla uyabilir.	Zaman bazlı split ve test skoru raporlandı.
Rejim değişimi	Piyasa davranışı yıl bazında değişebilir.	Validation/test ayrımı yapıldı.
Veri sızıntısı	Gelecek bilgi özelliğe karışabilir.	Lag/rolling disiplinine uyuldu.
Canlı demo arızası	Checkpoint inference gecikebilir.	Streamlit demo hızlı veri tabanlı panel olarak hazırlandı.
Yanlış kullanım	Tahminler yatırım tavsiyesi sanılabilir.	Akademik kullanım uyarısı verildi.

Gelecek çalışmalarda walk-forward yeniden eğitim, SHAP/LIME açıklanabilirliği, quantile regression, Monte Carlo dropout, GARCH ölçekleme ve haber takvimi entegrasyonu denenebilir.

14. Sonuç

Bu dönem projesi, bir yapay zeka projesinin veri toplamadan çalışan demoya kadar uzanan yaşam döngüsünü uygulamalı biçimde tamamlamıştır. En önemli bulgu, EUR/USD gibi kısa vadeli finansal serilerde naive baseline modellerinin RMSE bakımından çok güçlü kalmasıdır.

Buna rağmen XGBoost, Random Forest ve LightGBM yön doğruluğunda %51 seviyesini aşarak feature setinin sınırlı sinyal taşıdığını göstermiştir. Derin öğrenme modelleri mimari çeşitlilik sağlamış; ancak daha karmaşık modelin otomatik olarak daha iyi sonuç anlamına gelmediği görülmüştür.

Nihai Streamlit arayüzü, veri, metrik, tahmin ve senaryo üretimini tek panelde birleştirerek çalışan demo beklentisini karşılar. Repo yapısı, rapor, video ve kullanım talimatlarıyla final teslim paketi tamamlanmıştır.

Kaynakça

- SUBÜ EEF Yapay Zekaya Giriş Dersi Dönem Projesi Kılavuzu, 2024-2025 Bahar Dönemi.
- Pedregosa et al., Scikit-learn: Machine Learning in Python, JMLR, 2011.
- Chen and Guestrin, XGBoost: A Scalable Tree Boosting System, KDD, 2016.
- Ke et al., LightGBM: A Highly Efficient Gradient Boosting Decision Tree, NeurIPS, 2017.
- Hochreiter and Schmidhuber, Long Short-Term Memory, Neural Computation, 1997.
- Vaswani et al., Attention Is All You Need, NeurIPS, 2017.
- Yoon, Jarrett and van der Schaar, Time-series Generative Adversarial Networks, NeurIPS, 2019.
- Project repository: <https://github.com/somethinkwronghere/yapay-zeka-donem-projesi>

Ek A. Repo Yapısı

Klasör	İçerik
/data	Ham ve işlenmiş veri, skor tabloları ve checkpoint dosyaları.
/notebooks	EDA, baseline, ML karşılaştırma ve DL eğitim defterleri.
/src	Veri yükleme, özellik üretimi, metrikler ve model sınıfları.
/api	Streamlit demo uygulaması.
/docs	Plan, önceki çalışmalar, görseller ve final rapor klasörü.

Ek B. Final Kontrol Listesi

- GitHub repo bağlantısı hazır.
- README ve API kullanım açıklaması güncel.
- Streamlit demo yerelde çalışıyor.
- Model skorları tek tabloda birleştirildi.
- LSTM ve Transformer checkpoint dosyaları repo içinde.
- Ekran videosu MP4 olarak üretildi.
- Final rapor DOCX/PDF çıktısı üretildi.
- Finansal tavsiye olmadığı arayüz ve raporda belirtildi.